

A large, multi-level library with curved wooden bookshelves filled with books. The space is lit by warm, ambient light. In the foreground, there are black wooden study carrels and a small black table with a lamp. The title text is overlaid on the right side of the image.

# The College Application Problem

Cristóbal Godoy y Fraick Reyes

-

01

02



# Introducción del problema



$$\begin{aligned} &\text{maximize} && v(\mathcal{X}) = \mathbb{E}[\max\{t_j Z_j : j \in \mathcal{X}\}] \\ &\text{subject to} && \mathcal{X} \subseteq \mathcal{C}, \quad \sum_{j \in \mathcal{X}} g_j \leq H \end{aligned}$$

Donde  $\mathcal{C} = \{1 \dots m\}$  es una lista de índices que representan las universidades a las que vamos a postular,  $H > 0$  es el presupuesto; para  $j = 1 \dots m$ ,  $g_j, t_j > 0$  son el costo y la utilidad de postular a la universidad  $j$  respectivamente y  $Z_j \sim \text{Ber}(f_j)$ .

$$\begin{aligned} &\text{maximize} && v(\mathcal{X}) = \sum_{j \in \mathcal{X}} \left( f_j t_j \prod_{\substack{i \in \mathcal{X}: \\ i > j}} (1 - f_i) \right) \\ &\text{subject to} && \mathcal{X} \subseteq \mathcal{C}, \quad \sum_{j \in \mathcal{X}} g_j \leq H \end{aligned}$$

# Simulated Annealing



**Input:** Utility values  $t(0, \infty)^m$ , admissions probabilities  $f \in (0, 1]^m$ , application costs  $g \in (0, \infty)^m$ , budget  $H \in (0, \infty)^m$ .

**Parameters:** Initial temperature  $T \geq 0$ , temperature reduction parameter  $r \in (0, 1]$ , number of iterations  $N$ .

```
1 Add schools to  $\mathcal{X}$  in descending order by  $f_j t_j / g_j$  until the budget is exhausted;
2 for  $i = 1 \dots N$  do
3    $\mathcal{X}_n \leftarrow \text{copy}(\mathcal{X})$ ;
4   Add random schools from  $\mathcal{C} \setminus \mathcal{X}$  to  $\mathcal{X}_n$  until  $\mathcal{X}_n$  infeasible;
5   Remove random schools in  $\mathcal{X}$  from  $\mathcal{X}_n$  until feasibility restored;
6    $\Delta = v(\mathcal{X}_n) - v(\mathcal{X})$ ;
7   if  $\Delta \geq 0$  then  $\mathcal{X} \leftarrow \mathcal{X}_n$  else  $\mathcal{X} \leftarrow \mathcal{X}_n$  with probability  $\exp(\Delta/T)$ ;
8    $T \leftarrow rT$ ;
9 end
10 return the best  $\mathcal{X}$  found
```

02

03

04






# Generación de datos

Para obtener datos generamos  $(t_j)_j \sim \text{Exp}(10)$  aproximando al entero superior más cercano. Para obtener correlación negativa entre  $t_j$  y  $f_j$ , definimos  $f_j = 1/(t_j + 10Q_j)$ , donde  $Q_j \sim \text{Unif}([0, 1))$ . Los  $(g_j)_j \sim \text{Unif}(\{5, \dots, 10\})$  y definimos  $H = \lfloor \frac{1}{2} \sum g_j \rfloor$ .

Un ejemplo de generar 10 universidades es:

```
Utilidades: [ 6.  6. 27. 19.  3.  4.  6.  3.  2. 15.]  
Costos: [ 6  6 10  5 10  9  6 10 10 10]  
Presupuesto: 41  
Parámetro Bernoulli: [0.09565584 0.09565584 0.03179231 0.04263639 0.13415356 0.11828518  
0.09565584 0.13415356 0.1549392  0.05140293]
```

Para lo siguiente fijamos  $m = 500$  universidades.

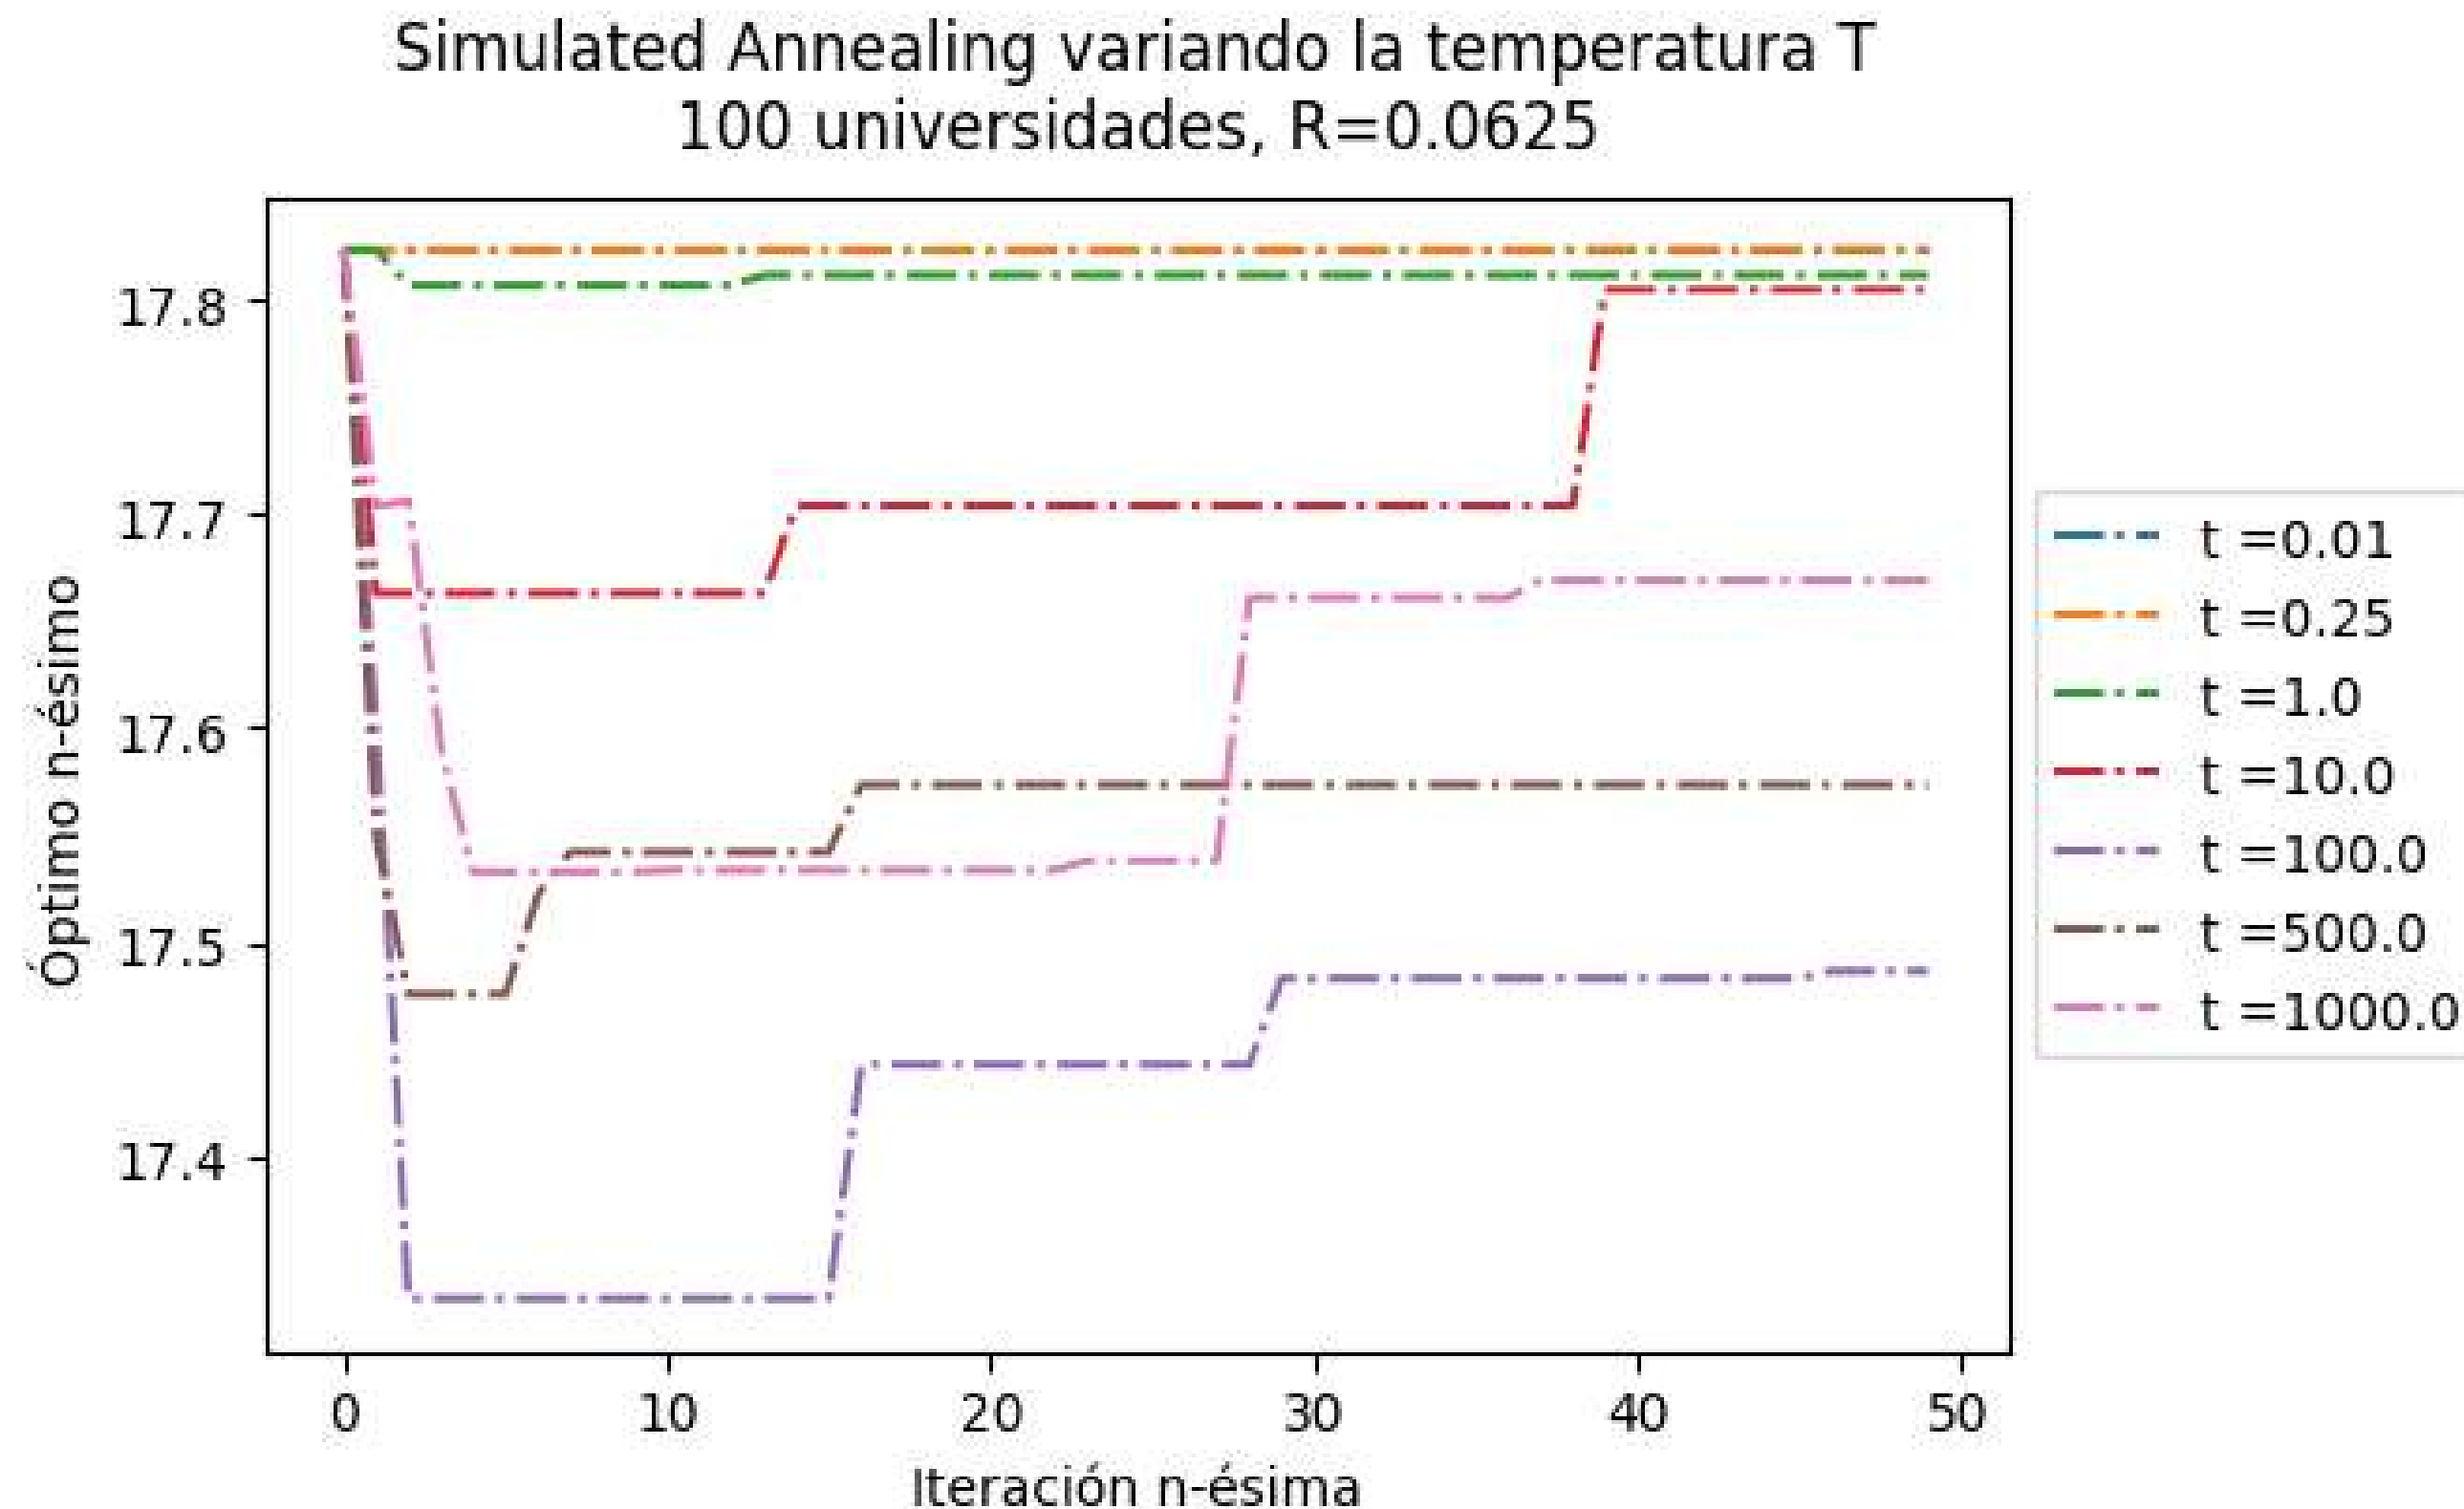


03

04

05

# Análisis del Algoritmo




# Análisis del Algoritmo




Variando factor de escala con temperatura  $T = 1/4$ :

Simulated Annealing variando el factor de escala R  
100 universidades,  $T=0.25$



Simulated Annealing variando el factor de escala R  
100 universidades,  $T=0.25$






# Comparación con Programación Dinámica



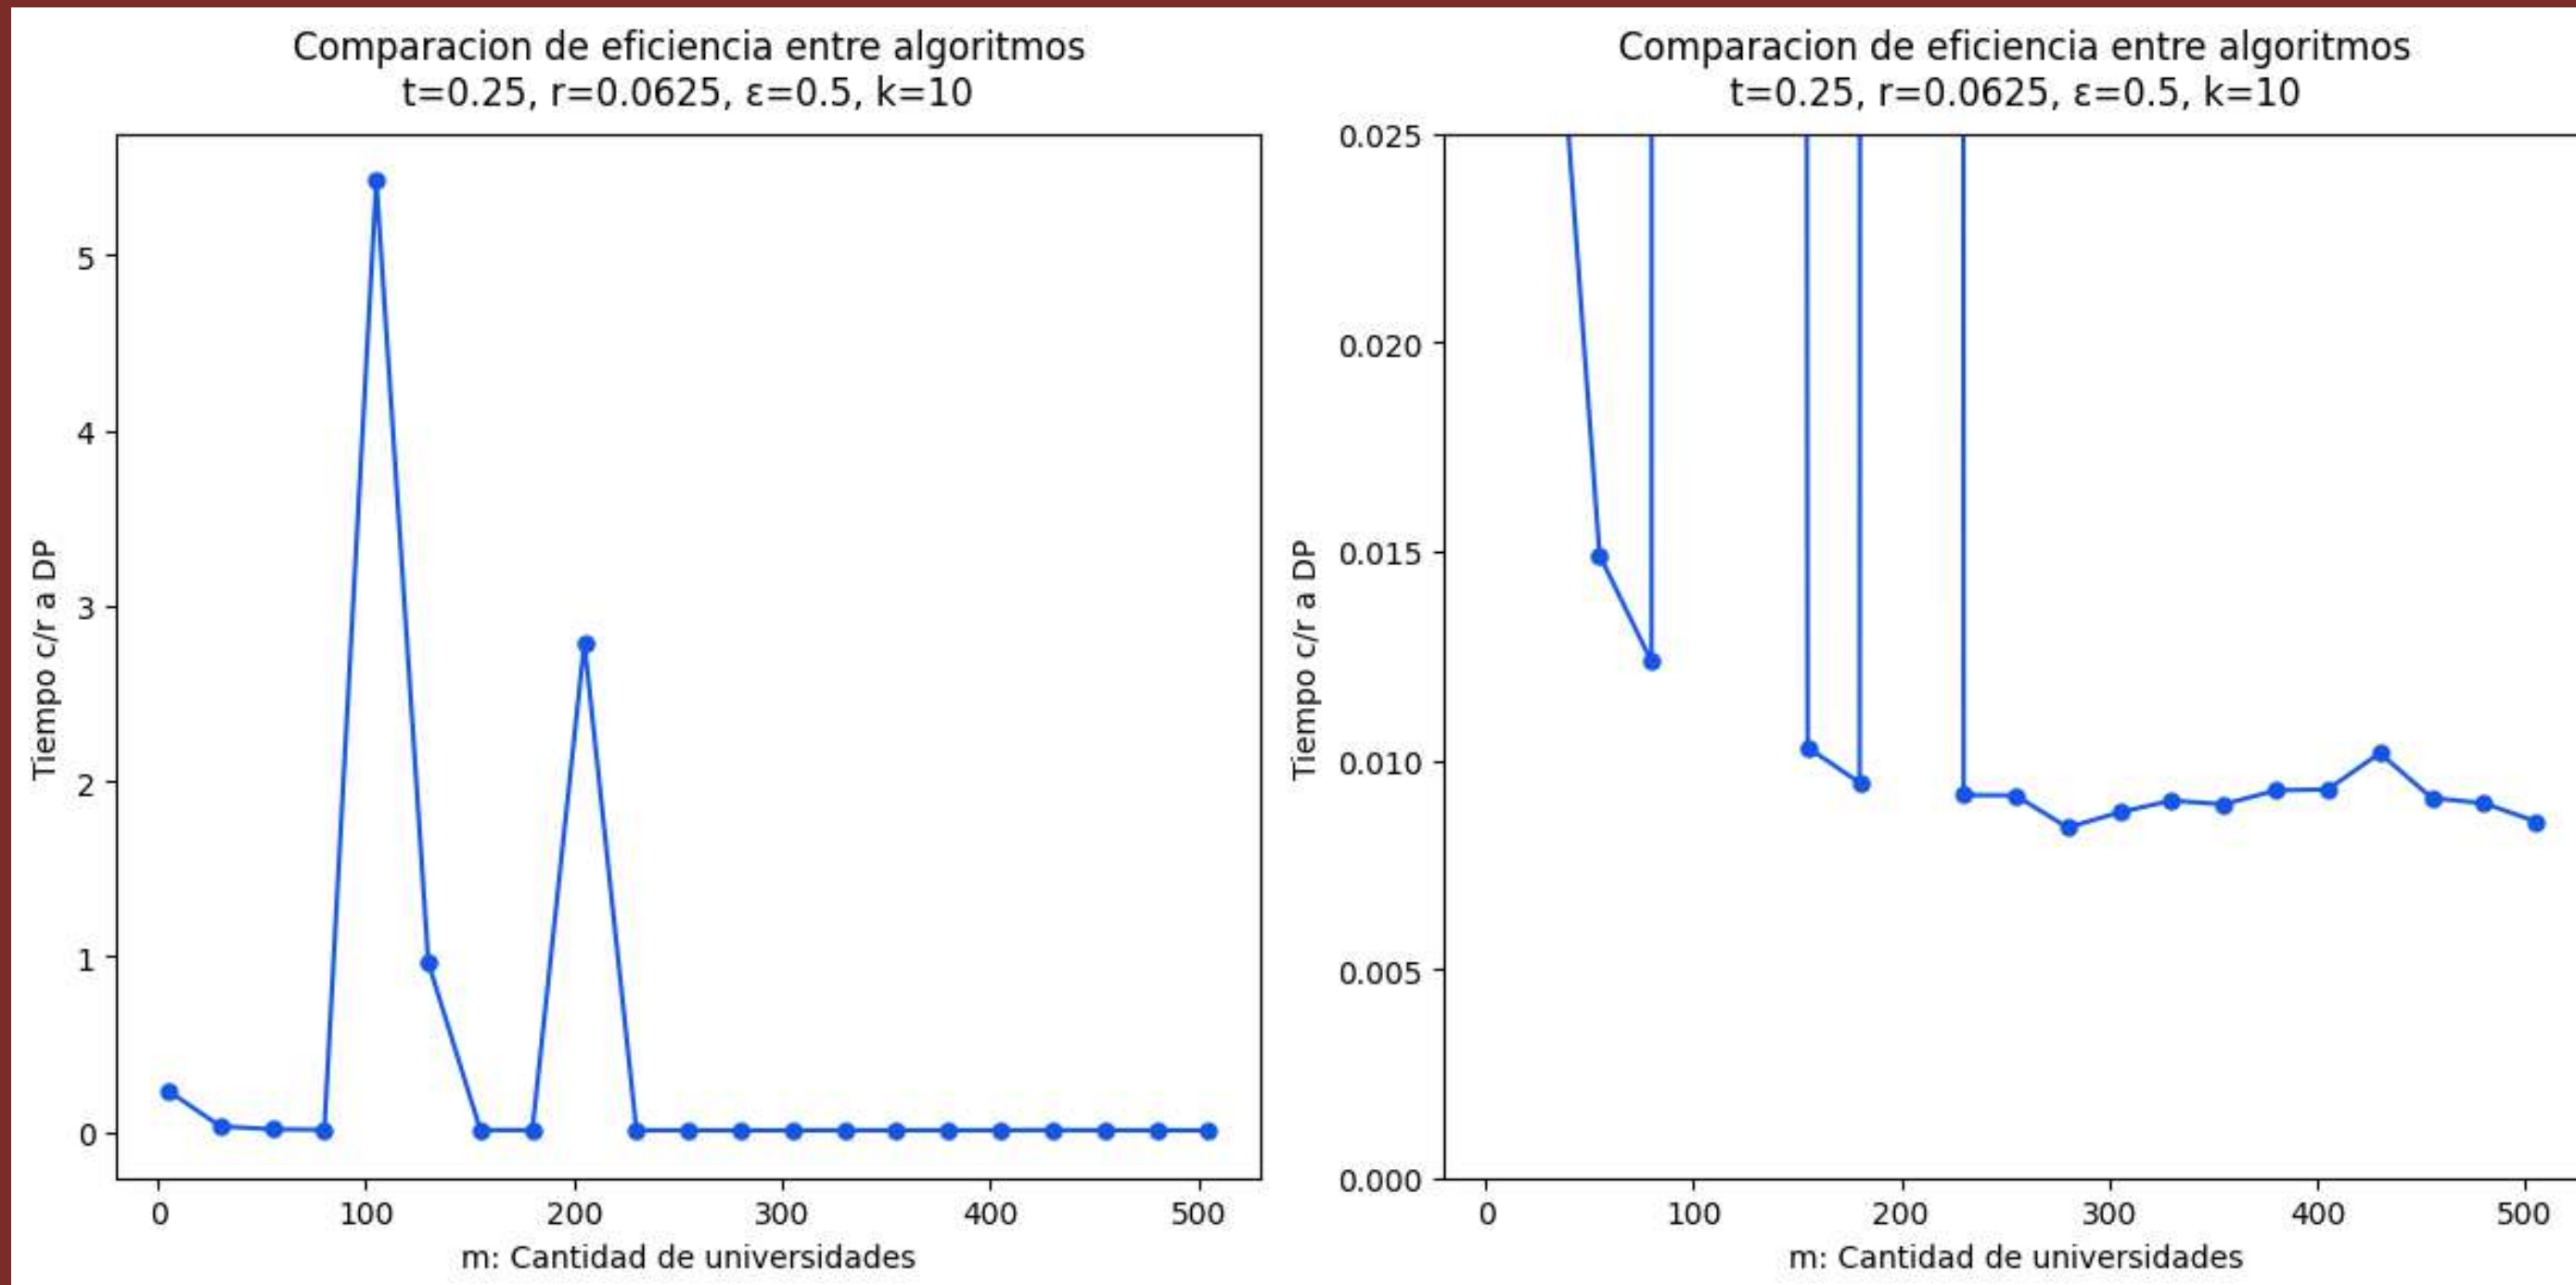
Test de eficacia:



# Comparación con Programación Dinámica



## Test de eficiencia:





# Variante de Función Objetivo



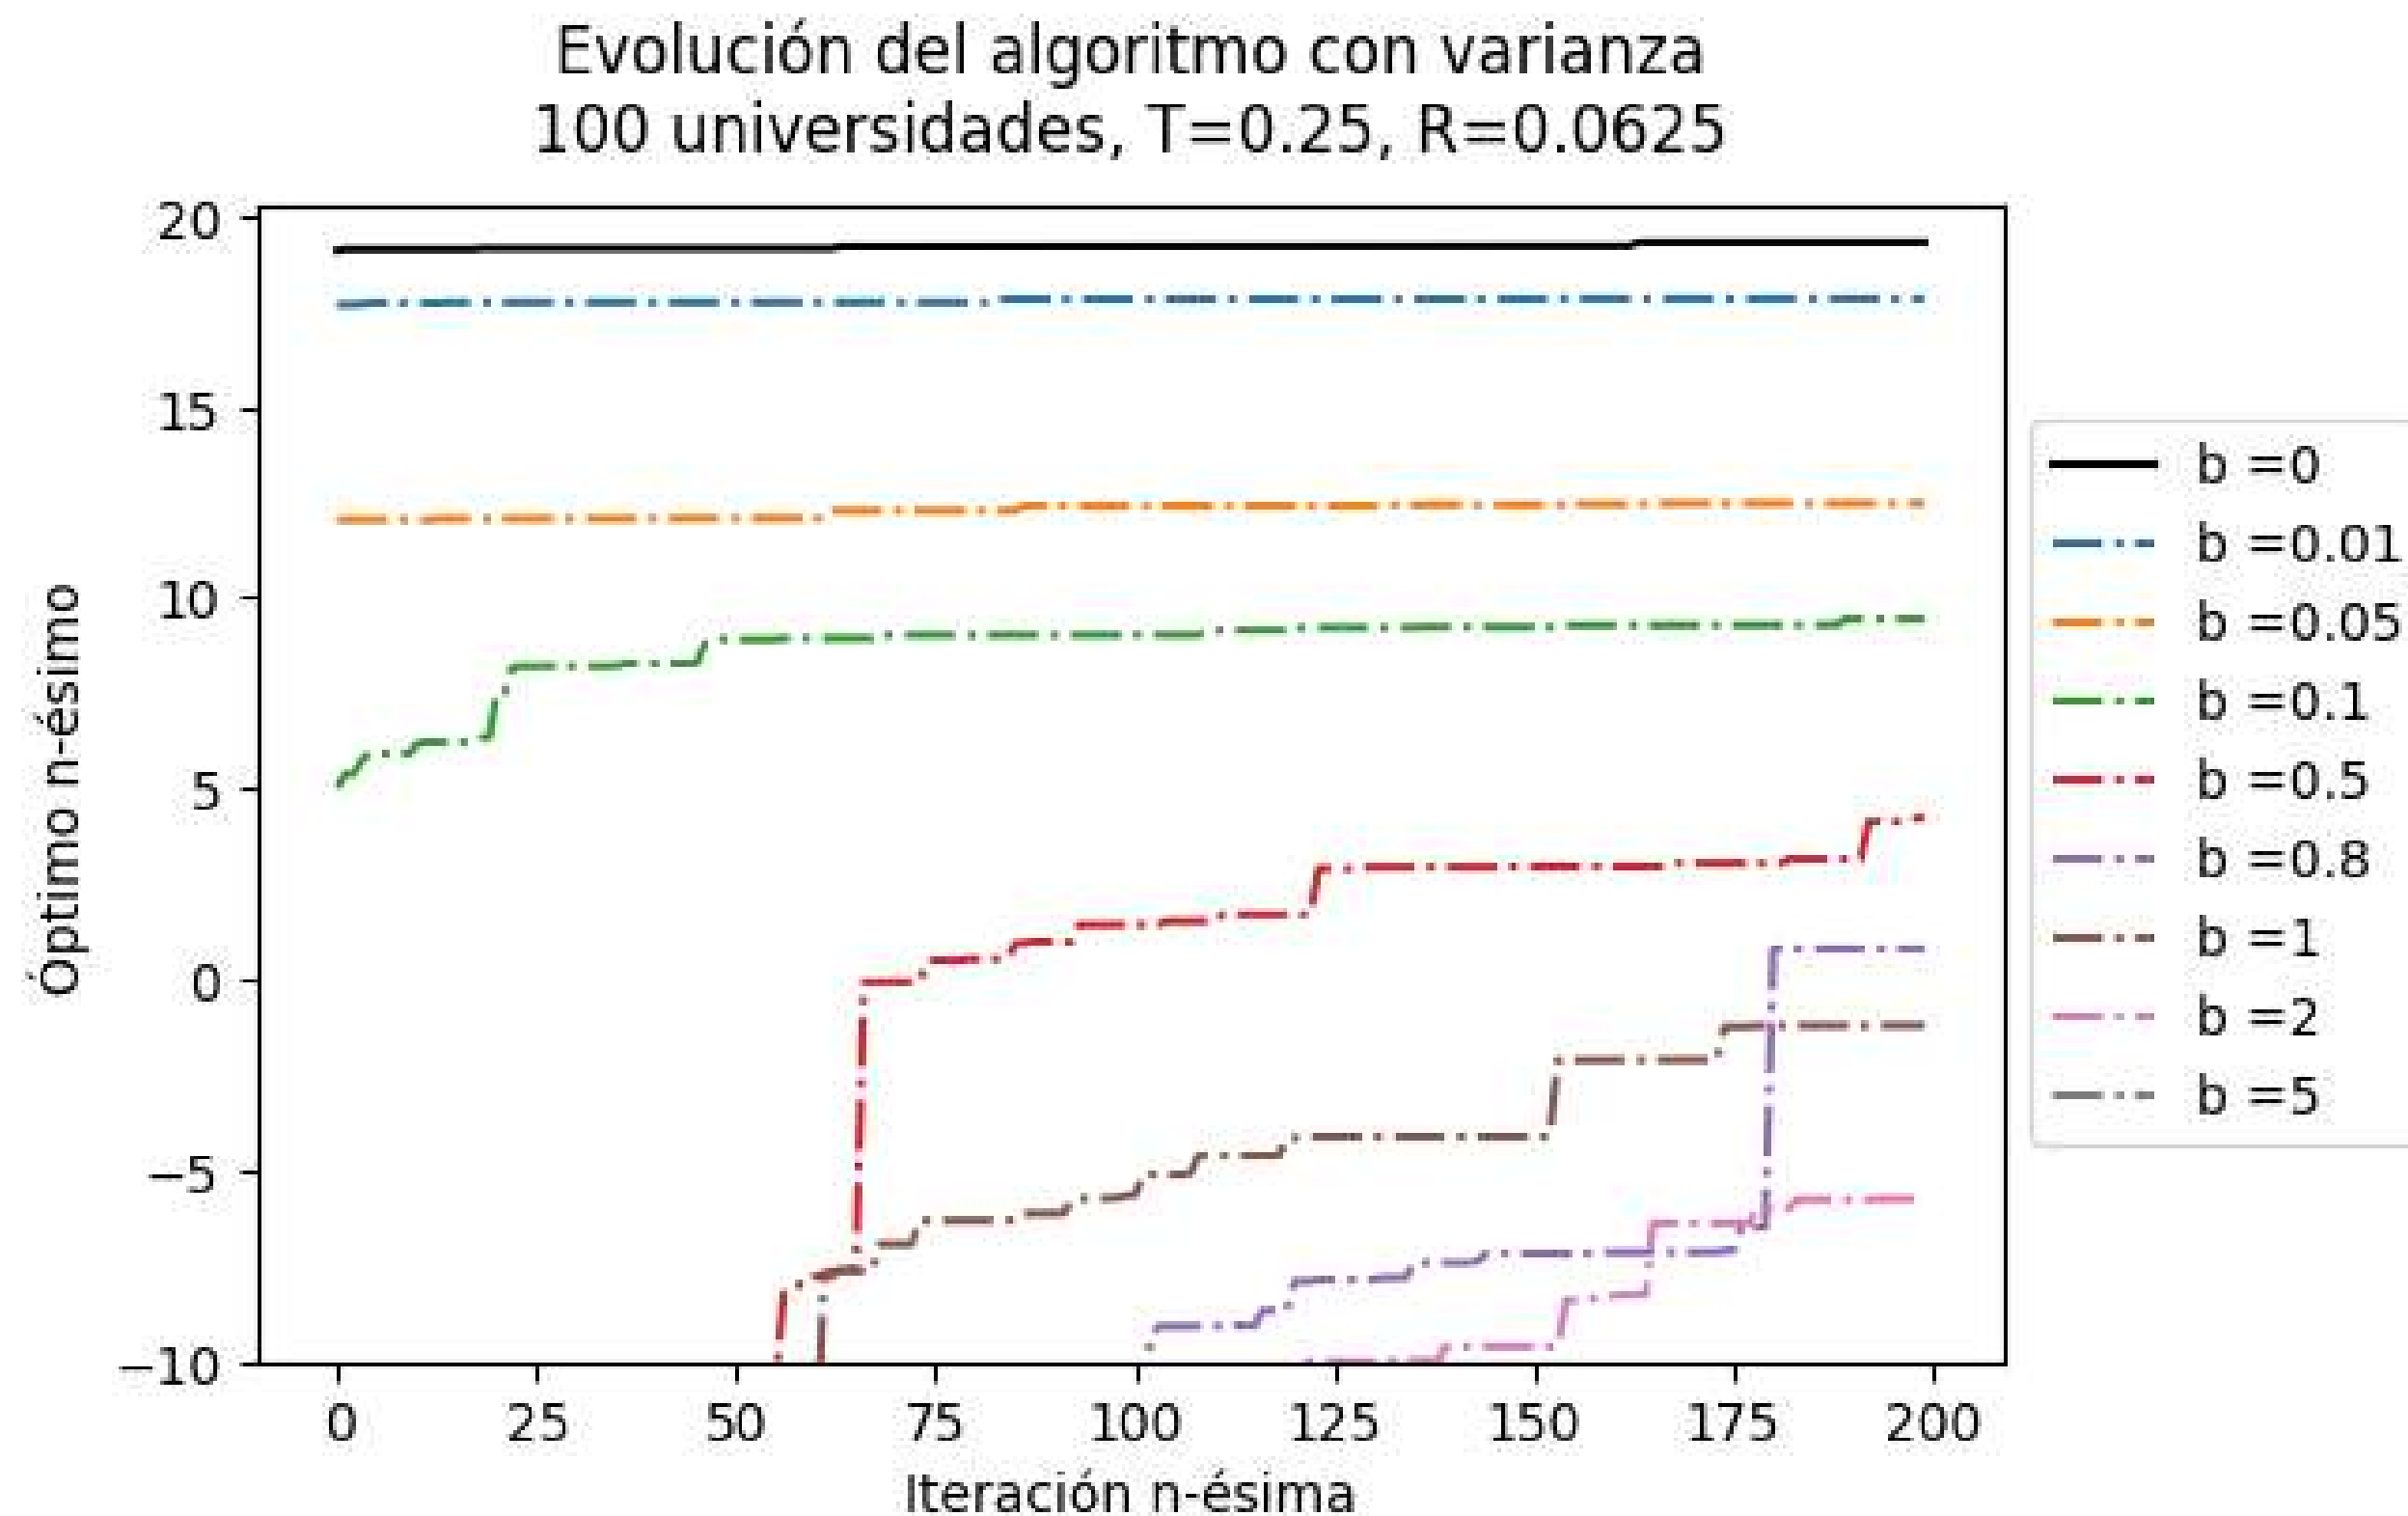
Podemos modificar la función objetivo para incorporar una penalización por la varianza  $\beta \geq 0$ , con lo siguiente:

$$v_{\beta}(\mathcal{X}) = \mathbb{E}[X] - \beta \text{Var}(X) = v(\mathcal{X}; \tau) + \beta v(\mathcal{X}; t)^2$$

Con  $\tau_j = t_j - \beta t_j^2$ .

A continuación estudiaremos el comportamiento de las soluciones variando este parametro de penalización.

# Variante de Función Objetivo





# Variante de Función Objetivo



Quisimos ver si cambiaban las soluciones óptimas dada la penalización, mostramos un caso con 10 universidades:

```
=====
f= [0.15  0.131 0.161 0.074 0.082 0.051 0.056 0.04  0.025 0.021]
b= 0:  [0.  0.  0.  0.  0.  1.  1.  1.  1.  1.]
b= 0.01 : [0.  0.  0.  0.  1.  1.  1.  0.  1.  1.]
b= 0.05 : [0.  0.  1.  1.  1.  1.  1.  0.  0.  0.]
b= 0.1 : [0.  1.  1.  1.  1.  1.  0.  0.  0.  0.]
b= 0.5 : [1.  1.  1.  1.  0.  1.  0.  0.  0.  0.]
b= 0.8 : [1.  1.  1.  1.  0.  1.  0.  0.  0.  0.]
b= 1 : [1.  1.  1.  1.  0.  1.  0.  0.  0.  0.]
b= 2 : [1.  1.  1.  1.  0.  1.  0.  0.  0.  0.]
b= 5 : [1.  1.  1.  1.  0.  1.  0.  0.  0.  0.]
=====
```

# Conclusiones



01

Eficacia

Simulated Annealing converge el óptimo salvo un error menor al 3% y la gran mayoría de veces menor al 1% .

02

Eficiencia

Simulated Annealing suele converger considerablemente más rápido que el algoritmo de programación dinámica para gran cantidad de universidades.

03

Variante

Tomar en cuenta el riesgo a postular puede afectar bastante en la solución óptima si la penalización es suficientemente grande.

## Referencias:

[1] Max Kapur, Sung-Pil Hong (2022); The College Application Problem; arXiv:2205.01869



# Extra



## Algoritmo Programación Dinámica:

$$V[j, h] = \max \{ V[j - 1, h], (1 - f_j)V[j - 1, h - g_j] + f_j t_j \}$$

**Algorithm 3:** Dynamic program for Ellis's problem with integral application costs.

**Input:** Utility values  $t \in (0, \infty)^m$ , admissions probabilities  $f \in (0, 1]^m$ , application costs  $g \in \mathbb{N}^m$ , budget  $H \in \mathbb{N}$ .

```
1 Index schools in ascending order by  $t$ ;  
2 Fill a lookup table with the values of  $V[j, h]$ ;  
3  $h \leftarrow H$ ;  
4  $\mathcal{X} \leftarrow \emptyset$ ;  
5 for  $j = m, m - 1, \dots, 1$  do  
6   if  $V[j - 1, h] < V[j, h]$  then  
7      $\mathcal{X} \leftarrow \mathcal{X} \cup \{j\}$ ;  
8      $h \leftarrow h - g_j$ ;  
9   end  
10 end  
11 return  $\mathcal{X}$ 
```